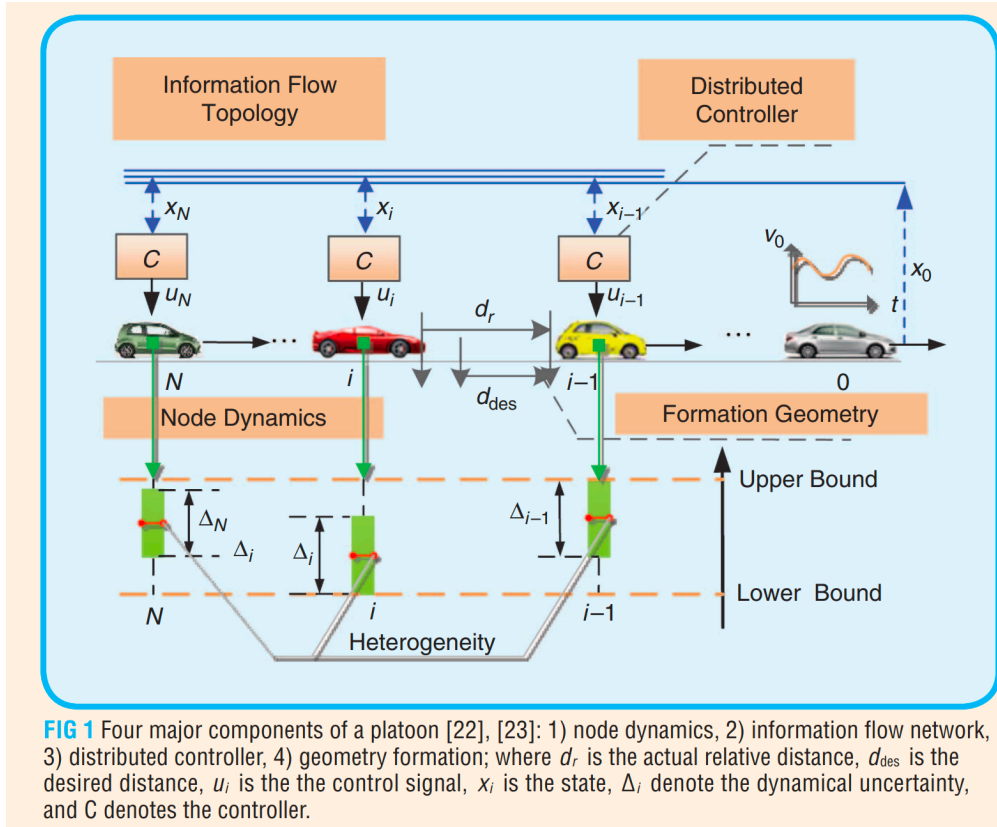


如图所示对于一个platoon，其主要包含四个元素node dynamics (ND), information flow network (IFN), distributed controller (DC), formation geometry (FG)。



## Node dynamics

third-order相比second-order的好处是使得state增加了一维，可以更好的模拟powertrain dynamics的输入输出。

### Single integrator model

这是一种最简单的情况，直接将车辆的速度作为control input，将位置作为state

$$\dot{p}_i(t) = u_i(t)$$

### Second-order linear model (position-velocity)

例如：

$$\begin{cases} \dot{p}_i = v_i \\ \dot{v}_i = u_i, \quad i = 0, 1, \dots, n \end{cases}$$

$$u_i = f_i(p_{i-1}, p_i, p_{i+1}, p_{s_i}) + g_i(v_{i-1}, v_i, v_{i+1}), \quad i = 1, \dots, n-1$$

其中 $u_i$ 为车的加速度， $f_i(*)$ 和 $g_i(*)$ 分别为位置和速度的函数。

## Second-order nonlinear model (position-velocity)

例如：

$$\begin{aligned}\dot{p}_i(t) &= v_i(t), i \in \mathcal{V}_N \\ \dot{v}_i(t) &= \text{sat}(u_i(t)) + f_i(p_i(t), v_i(t), t) + w_i(t)\end{aligned}$$

其中 $f_i(*)$ 为环境的非线性干扰，例如随机的加速干扰、风阻、路况等等。 $\|w_i(t)\| \leq \bar{w}$ 为控制输入的干扰。 $\text{sat}(*)$ 函数规定了 $u_i(t)$ 的上界为 $u_{Mi}$ 。同样，其作为一种开环控制。

$$\text{sat}(u_i(t)) = \begin{cases} u_{Mi} \text{sgn}(u_i(t)), & \text{if } |u_i(t)| \geq u_{Mi} \\ u_i(t), & \text{if } |u_i(t)| \leq u_{Mi} \end{cases}$$

## Third-order nonlinear model (position-velocity-force)

形如：

$$\begin{aligned}\dot{p}_i(t) &= v_i(t) \\ \dot{v}_i(t) &= \frac{1}{m_i} F_i(t) - \frac{K_{di}}{m_i} v_i^2(t) - \frac{d_{mi}}{m_i} \\ \dot{F}_i(t) &= \frac{1}{\tau_i} u_i(t) - \frac{1}{\tau_i} F_i(t)\end{aligned}$$

其中 $F_i(t)$ 为第 $i$ 辆车的引擎施加在车上的力， $m_i$ 为第 $i$ 辆车的质量， $\tau_i$ 为第 $i$ 辆车的引擎时延， $K_{di}$ 为气动阻力参数， $d_{mi}$ 为机器阻力。

## Third-order nonlinear model (position-velocity-acceleration)

形如：

$$\begin{aligned}\dot{p}_i(t) &= v_i(t) \\ \dot{v}_i(t) &= a_i(t) \\ \dot{a}_i(t) &= \frac{1}{m_i \tau_i} u_i(t) - \frac{2K_{di}}{m_i} v_i(t) a_i(t) - \frac{1}{\tau_i} \left( a_i(t) + \frac{K_{di}}{m_i} v_i^2(t) + \frac{d_{mi}}{m_i} \right)\end{aligned}$$

和position-velocity-force没什么区别，将 $F_i(t)$ 用 $a_i(t)$ 和 $v_i(t)$ 替代即可，这样的好处是加速度更容易分析。

## Third-order linear model (position-velocity-acceleration)

形如：

$$\begin{aligned}\dot{p}_i(t) &= v_i(t) \\ \dot{v}_i(t) &= a_i(t) \\ \dot{a}_i(t) &= \frac{1}{\tau_i} c_i(t) - \frac{1}{\tau_i} a_i(t)\end{aligned}$$

其中state包含位置、速度、加速度。其中控制输入与加速度的微分成正比。

当控制器已知环境参数时，可将非线性模型线性化， $u_i(t)$ 满足：

$$u_i(t) = m_i c_i(t) + K_{di} v_i^2(t) + d_{mi} + 2\tau_i K_{di} v_i(t) a_i(t)$$

## Information Flow Topology (IFT)

一些常用的Information Flow传递方式如下，(a)和(c)图分别为predecessor following (PF)、bidirectional (BD) topologies，它们常用于使用雷达等传感器的车队中，只能测量相邻车辆的速度、位置等信息。(b)、(d)、(e)、(f)是当引入车联网后的车车通信模型，分别表示predecessor-following leader (PFL) type, bidirectional leader (BDL) type, two predecessorfollowing (TPF) type, and two predecessor-following leader (TPFL) type。




FIG 2 Typical IFTs: (a) PF, (b) BD, (c) PFL, (d) BDL, (e) TPF, (f) TPFL.

## Distributed Controller

四种常用的distributed controller分别为linear consensus control, robust control, distributed sliding mode control, distributed model predictive control。前两者用于linear dynamic model，后两者用于non-linear dynamic model。

### linear consensus control

线性控制的通常形式为：

$$u_i(t) = - \sum_{j \in \mathbb{I}_i} [k_{ij,p} (p_i(t - \gamma_{ii}) - p_j(t - \gamma_{ij}) - d_{i,j}) + k_{ij,v} (v_i(t - \gamma_{ii}) - v_j(t - \gamma_{ij})) + k_{ij,a} (a_i(t - \gamma_{ij}) - a_j(t - \gamma_{ij}))]$$

其中 $k_{ij,\#}$  ( $\# = p, v, a$ )，其代表controller gain，分别是间距误差的参数、速度误差的参数和加速度误差的参数。

$\gamma_{ii}$ 为车辆接受自身state的时延， $\gamma_{ij}$ 为i车辆接受j车辆state的时延。

## distributed robust control

$H_\infty$  control可以保证string stability, 并且适合具有异构车辆、具有不确定的dynamics和时延的车队。但是缺点是它只适合于特定的车队, 且当车队的通信模式变化, 控制模型要重新设计。

## distributed sliding control

$\dot{x} = f(x) + u$ , 控制目标为 $x \rightarrow x_d$ , 其中 $\|f(x)\| < \rho(x)$


$$\dot{e} = \dot{x}_d - \dot{x} = \dot{x}_d - f(x) - u$$

$$\text{令 } u = \dot{x}_d + ke + \rho * \text{sgn}(e)$$

这样就可以令 $\lim_{\infty} e = x_d - x = 0$ 当 $t$ 趋向于无穷时。

$$\text{代入得 } \dot{e} = -ke - f(x) - \rho(x)\text{sgn}(e)$$

其中后面的部分 $-f(x) - \rho(x)\text{sgn}(e)$ 为控制项, 其会不断的将偏离的点滑到这条黑线 $\dot{e} = -ke$ 上。



## distributed model predictive control

通过模型来预测系统在某一时刻实际内的表现来进行优化控制。

有系统:  $x_{k+1} = Ax_k + Bu_k$

step 1: 估计/测量系统当前的状态。

step 2: 基于 $u_k, u_{k+1} \dots u_{k+n}$ 来进行最优化。(预测区间/控制区间)

$$\text{代价函数 } J = \sum_k^{N-1} E_k^T Q E_k + u_k^T R u_k + E_N^T F E_N$$

三项分别为每个step的error误差、控制的能量消耗、最终时刻的误差。

step 3: 只施加 $u_k$

重点在于如何做最优化, 最常用的方法为二次规划QP。

其一般形式为:  $\min Z^T Q Z + C^T Z$

假设在 $k$ 时刻, 预测区间中的状态和控制输入可以表达为:

在  $k$  时刻.

$$X_k = \begin{bmatrix} x(k|k) \\ x(k+1|k) \\ x(k+2|k) \\ \vdots \\ x(k+N|k) \end{bmatrix}$$

$$U_k = \begin{bmatrix} u(k|k) \\ u(k+1|k) \\ \vdots \\ u(k+i|k) \\ \vdots \\ u(k+N|k) \end{bmatrix}$$

在  $k$  时刻的预测

预测区间  
Predictive Horizon.

代价函数为:

Cost function  
代价

$$J = \sum_{i=0}^{N-1} (x(k+i|k)^T Q x(k+i|k) + u(k+i|k)^T R u(k+i|k)) + x(k+N)^T F x(k+N)$$

误差加权  
输入加权  
终端状态

带如初始条件进行迭代:

初始条件

$$\begin{aligned} x(k|k) &= x_k \\ x(k+1|k) &= A x(k|k) + B u(k|k) = A x_k + B u(k|k) \\ x(k+2|k) &= A x(k+1|k) + B u(k+1|k) = A^2 x_k + A B u(k|k) + B u(k+1|k) \\ &\vdots \\ x(k+N|k) &= A^N x_k + A^{N-1} B u(k|k) + \dots + B u(k+N-1|k) \end{aligned}$$

$$X_k = \begin{bmatrix} I \\ A \\ A^2 \\ \vdots \\ A^N \end{bmatrix} x_k + \begin{bmatrix} 0 & 0 & \dots & 0 \\ B & 0 & \dots & 0 \\ AB & B & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \dots & B \end{bmatrix} \begin{bmatrix} u(k|k) \\ u(k+1|k) \\ \vdots \\ u(k+N-1|k) \end{bmatrix}$$

最后可以简化为:

$$X_k = M x_k + C U_k$$

将代价函数写成矩阵形式:

$$\begin{aligned} J &= \sum_{i=0}^{N-1} (x(k+i|k)^T Q x(k+i|k) + u(k+i|k)^T R u(k+i|k)) + x(k+N)^T F x(k+N) \\ &= \begin{bmatrix} x(k|k) \\ x(k+1|k) \\ \vdots \\ x(k+N|k) \end{bmatrix}^T \begin{bmatrix} Q & 0 & \dots & 0 \\ 0 & R & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & F \end{bmatrix} \begin{bmatrix} x(k|k) \\ x(k+1|k) \\ \vdots \\ x(k+N|k) \end{bmatrix} = X_k^T \bar{Q} X_k \\ &= (M x_k + C U_k)^T \bar{Q} (M x_k + C U_k) + U_k^T \bar{R} U_k \\ &= x_k^T M^T \bar{Q} M x_k + 2 x_k^T M^T \bar{Q} C U_k + U_k^T (C^T \bar{Q} C + \bar{R}) U_k \end{aligned}$$

展开后化简, 成为了二次规划的一般形式 (一个二次项、一个线性项和一个初始项):

$$\begin{aligned}
 &= \underbrace{x_k^T M^T \bar{Q} M x_k}_G + \underbrace{x_k^T M^T \bar{Q} C u_k}_{2x_k^T C^T \bar{Q} M u_k} + \underbrace{u_k^T C^T \bar{Q} M x_k}_{\text{same as above}} + \underbrace{u_k^T C^T \bar{Q} C u_k}_{C^T \bar{Q} C + R = H} \\
 &\boxed{J = x_k^T G x_k + 2x_k^T E u_k + u_k^T H u_k}
 \end{aligned}$$

## Formation Geometry (FG)

可以理解为控制的目标，它通常包括以下三种：1) constant distance (CD) policy, 2) constant time headway (CTH) policy, and 3) nonlinear distance (NLD) policy。

control objective:

- a) to ensure all the vehicles in the same group to move at the same speed with the leader
- b) to maintain the desired spaces between adjacent vehicles

### constant distance policy

相邻两辆车的理想间距为常数，与速度无关（高交通容量）：

$$d_{i-1,i} = d_0, i \in \mathcal{N}$$

### constant time headway policy

此时相邻两辆车的理想间距与速度有关（限制部分交通容量），其中 $t_h$ 为time headway。

$$d_{i-1,i} = t_h v_i + d_0, i \in \mathcal{N}$$

### nonlinear distance policy

这种情况下，两辆车的desired distance为关于速度的函数。这种方法有潜力在保证交通流稳定性的情况下提高交通容量。

$$d_{i-1,i} = g(v_i), \quad i \in \mathcal{N}$$